


# Algoritmos genéticos



# Generalidades



Genetic Algorithm (GA) es una técnica de optimización basada en búsquedas basada en los principios de Genética y Selección Natural.

Se usa con frecuencia para encontrar soluciones óptimas o casi óptimas para problemas difíciles que, de lo contrario, llevaría toda la vida resolver.

Se usa con frecuencia para resolver problemas de optimización, en investigación y en aprendizaje automático.

# Optimización

La optimización es el proceso de **hacer algo mejor**.

La optimización se refiere a encontrar los valores de las entradas de tal forma que obtengamos los "mejores" valores de salida. La definición de "mejor" varía de un problema a otro, pero en términos matemáticos, se refiere a maximizar o minimizar una o más funciones objetivas, al variar los parámetros de entrada.



# Optimización



El **conjunto de todas las posibles soluciones** o valores que pueden tomar las entradas conforman el **espacio de búsqueda**.

En este espacio de búsqueda, se encuentra un **punto** o un **conjunto de puntos** que proporciona la **solución óptima**.

El objetivo de la optimización es **encontrar** ese punto o conjunto de puntos en el espacio de búsqueda.

# Algoritmos Genéticos



Los algoritmos (GA) son algoritmos basados en búsquedas basados en los conceptos de selección natural y genética.

En GA, tenemos un grupo o una población de soluciones posibles para el problema dado.

Estas soluciones luego experimentan recombinación y mutación (como en la genética natural), produciendo nuevos hijos, y el proceso se repite a lo largo de varias generaciones.

Las personas más aptas (**higher fitness**) tienen más posibilidades de aparearse y obtener más individuos "más aptos".

# Ventajas de los algoritmos Genéticos



- No requiere ninguna información derivada (que puede no estar disponible para muchos problemas del mundo real).
- Es más rápido y más eficiente en comparación con los métodos tradicionales.
- Optimiza tanto funciones continuas como discretas y también problemas multiobjetivos.
- Proporciona una lista de soluciones "buenas" y no solo una solución única.
- Útil cuando el espacio de búsqueda es muy grande y hay una gran cantidad de parámetros involucrados.


# Limitaciones de los algoritmos Genéticos



- Los GA no son adecuados para todos los problemas, especialmente los problemas que son simples y para los que se dispone de información derivada.
- El valor de la aptitud (**fitness**) se calcula repetidamente, lo que puede ser computacionalmente costoso para algunos problemas.
- Al ser estocástico, no hay garantías sobre la optimalidad o la calidad de la solución.
- Si no se implementa correctamente, la GA puede no converger a la solución óptima.

# Fallo de los métodos de gradiente

- Los métodos tradicionales basados en cálculo funcionan comenzando en un punto aleatorio y moviéndose en la dirección del gradiente, hasta que lleguemos a la cima de la colina.
- En la mayoría de los problemas reales, estos métodos se quedan o tienden a quedarse atrapados en soluciones locales.





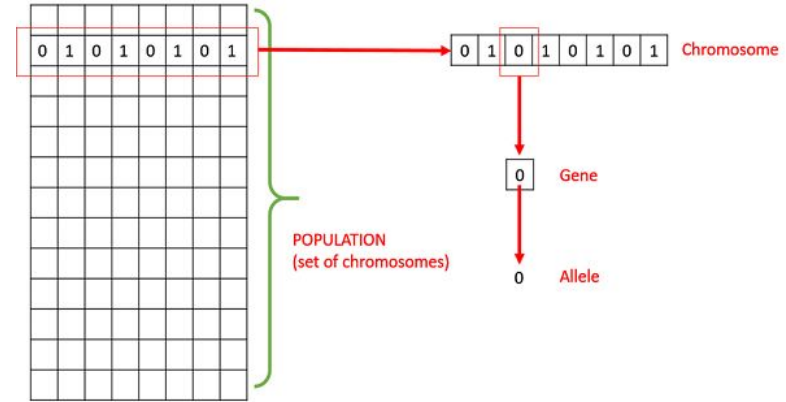
# Fundamentos

**Población:** es un subconjunto de todas las soluciones posibles (codificadas) para el problema dado.

**Cromosomas:** un cromosoma es una de esas soluciones para el problema dado.

**Gen:** es la posición de un elemento de un cromosoma.

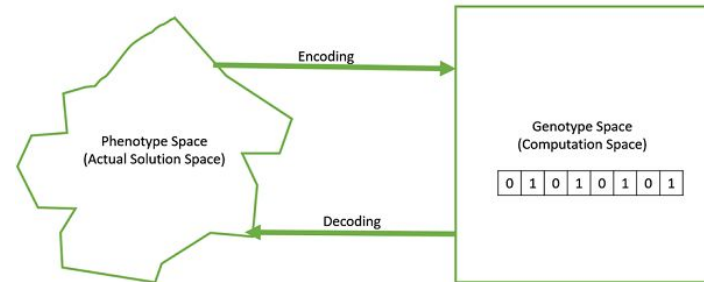

**Alelo:** es el valor que un gen tiene para un cromosoma en particular.



# Fundamentos

**Genotipo:** el genotipo es la población en el espacio de cálculo. Para ser procesador por un algoritmo.

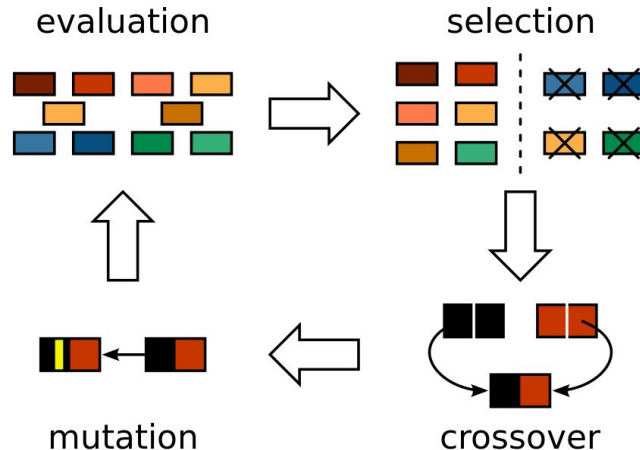
**Fenotipo:** el fenotipo es la población en el verdadero espacio de soluciones del mundo real en el que las soluciones se representan de forma tal que se representan en situaciones del mundo real.



# Fundamentos

Función de **fitness**: es una función que toma la solución como entrada y produce la **idoneidad** de la solución como salida.

**Operadores genéticos**: alteran la composición genética de la descendencia. Estos incluyen crossover, mutación, selección, etc.




# Estructura de un GA

Comenzamos con una población inicial (que puede ser generada al azar o sembrada por otras heurísticas).

Se seleccionan los padres de esta población para el apareamiento.

Se aplican operadores de cruce y mutación a los padres para generar nuevos descendientes.

Y, finalmente, estos descendientes reemplazan a los individuos existentes en la población y el proceso se repite.



# Representación del genotipo

Una de las decisiones más importantes que se deben tomar al implementar un algoritmo genético es decidir la representación que utilizaremos para representar nuestras soluciones.

Se ha observado que la representación incorrecta puede conducir a un rendimiento deficiente de la GA.

## Tipos de representaciones:

- Binaria
- Real
- Entera

0	0	1	0	1	1	1	0	0	1
---	---	---	---	---	---	---	---	---	---

0.5	0.2	0.6	0.8	0.7	0.4	0.3	0.2	0.1	0.9
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

1	2	3	4	3	2	4	1	2	1
---	---	---	---	---	---	---	---	---	---

# Representación Binaria




En general representan ausencia o presencia de algún factor. Por ejemplo en el caso de un viajero que quiera saber qué objetos llevar para su viaje, el elemento  $n$  del cromosoma si está en 1 representa que ese objeto se va a llevar, 0 en caso contrario.

También podría representar una categorización, en la cual una serie de tareas se hace de una forma u otra. Y se quiere saber si hacer algunas tareas de la primera forma y otras de la segunda forma es mejor.

# Representación Real

Para los problemas donde queremos definir los genes usando variables continuas en lugar de discretas, la representación real es la más natural. Sin embargo, la precisión de estos números reales o de coma flotante está limitada a la computadora.

Podría pensarse un problema en el cual se tiene una red neuronal de una capa y se quiere minimizar el error de aprendizaje. Al ser los pesos aleatorios y reales, constituyen un genotipo (y a la vez fenotipo) del problema a resolver.



# Representación Entera



Para genes de valores discretos, no siempre podemos limitar el espacio de la solución al 'sí' o 'no' binarios. Por ejemplo, si queremos codificar las cuatro distancias: Norte, Sur, Este y Oeste, podemos codificarlas como  $\{0,1,2,3\}$ . En tales casos, es deseable la representación entera.

Mediante esta representación también se puede codificar el orden de un proceso.  
(Permutación)

Un ejemplo clásico de esta representación es el problema del viajero (TSP). En este, el viajero debe realizar un recorrido por todas las ciudades, visitar cada ciudad exactamente una vez y regresar a la ciudad de partida. La distancia total del recorrido debe ser minimizada. La solución es, naturalmente, una permutación de todas las ciudades.



# La población



La población es un subconjunto de soluciones en la generación actual. También se puede definir como un conjunto de cromosomas.

La diversidad de la población debería mantenerse, de lo contrario podría llevar a una convergencia prematura.

El tamaño de la población no se debe mantener muy grande, ya que puede hacer que ralentice la GA, mientras que una población más pequeña podría no ser suficiente para un buen grupo de apareamiento. Por lo tanto, un tamaño de población óptimo debe decidirse por ensayo y error.

# La población



La población es un subconjunto de soluciones en la generación actual. También se puede definir como un conjunto de cromosomas.

La diversidad de la población debería mantenerse, de lo contrario podría llevar a una convergencia prematura.

El tamaño de la población no se debe mantener muy grande, ya que puede hacer que ralentice la GA, mientras que una población más pequeña podría no ser suficiente para un buen grupo de apareamiento. Por lo tanto, un tamaño de población óptimo debe decidirse por ensayo y error.

# La población



La población generalmente se define como una matriz bidimensional de tamaño de la población por tamaño del cromosoma.

## Inicialización:

- **Random:** Soluciones completamente aleatorias.
- **Heurística:** No se han encontrado buenos resultados utilizando este método. Debido a que conlleva a soluciones similares y de poca diversidad.

# Modelos poblacionales



## **Estado constante:**

Se genera uno o dos descendencias en cada iteración y reemplazan a uno o dos individuos de la población.

## **Generacional:**

En un modelo generacional, se generan 'n' descendencias, donde n es el tamaño de la población, y la población completa es reemplazada por la nueva al final de la iteración.

# Función de aptitud (fitness)

Es una función que toma una solución candidata al problema como entrada y produce como salida la forma en que se "ajusta" la solución con respecto al problema en consideración.

El cálculo de la función de aptitud se realiza de forma repetida en una GA y, por lo tanto, debe ser lo suficientemente rápida.

0	1	2	3	4	5	6	Item Number
0	1	0	1	1	0	1	Chromosome
2	9	8	5	4	0	2	Profit Values
7	5	3	1	5	9	8	Weight Values

Knapsack capacity = 15  
Total associated profit = 18  
Last item not picked as it exceeds knapsack capacity

# Selección de los padres



La selección de los padres es el proceso de selección de los padres que se aparean y se recombinan para crear los descendientes para la próxima generación.

La selección de los padres es muy crucial para la tasa de convergencia de la AG ya que los buenos padres llevan a las personas a soluciones mejores y más adecuadas.

Mantener una buena diversidad en la población es extremadamente crucial para el éxito de una AG.

# Selección de los padres: Acorde al fitness




Cada individuo puede convertirse en un padre con una probabilidad que es proporcional a su aptitud (fitness).

Por lo tanto, las personas más en forma tienen más posibilidades de aparearse y propagar sus características a la próxima generación.

Por lo tanto, esta estrategia de selección aplica una presión de selección a las personas más aptas de la población, evolucionando mejores individuos a lo largo del tiempo.

# Selección de los padres: Acorde al fitness

Considera una rueda circular. La rueda se divide en  $n$  partes, donde  $n$  es el número de individuos en la población. Cada individuo obtiene una porción del círculo que es proporcional a su valor de condición física.




Chromosome	Fitness Value
A	8.2
B	3.2
C	1.4
D	1.2
E	4.2
F	0.3



# Selección de los padres: Acorde al fitness

## Método de la ruleta:

Se elige un punto fijo en la circunferencia de la rueda como se muestra (Fixed point) y se gira la rueda. La región de la rueda que se encuentra delante del punto fijo se elige como principal.



# Selección de los padres: Acorde al fitness



Está claro que un individuo en forma tiene una mayor porción en la rueda y, por lo tanto, una mayor posibilidad de aterrizar en frente del punto fijo cuando se gira la rueda.

Por lo tanto, la probabilidad de elegir un individuo depende directamente de su aptitud.



Implementación:

1. Cálculo de la suma ( $S$ ) de todas las aptitudes (fitnesses).
2. Generación de un número aleatorio entre 0 y  $S$ .
3. Comenzando desde la parte superior de la población, se van agregando las aptitudes a la suma parcial  $P$ , hasta  $P < \text{punto fijo}$ .
4. El individuo para el cual  $P$  excede punto fijo es el individuo elegido.

# Selección de los padres: Acorde al fitness

## Muestreo estocástico universal:

Es bastante similar a la selección de la rueda de la ruleta, sin embargo, en lugar de tener un solo punto fijo, tenemos varios puntos fijos, como se muestra en la siguiente imagen. Por lo tanto, todos los padres son elegidos en un solo giro de la rueda.




Chromosome	Fitness Value
A	8.2
B	3.2
C	1.4
D	1.2
E	4.2
F	0.3

# Selección de los padres: Torneo

En la selección de torneos K-Way, seleccionamos K individuos de la población al azar y seleccionamos a los mejores de estos para convertirnos en padres.


El mismo proceso se repite para seleccionar el siguiente padre. La selección de torneos también es muy popular en la literatura, ya que incluso puede funcionar con valores de aptitud negativos.



# Selección de los padres: Rank

Funciona también con valores de aptitud física negativos y se usa principalmente cuando los individuos en la población tienen valores de aptitud física muy cercanos (esto sucede generalmente al final de la ejecución del GA).

Cada solución tiene igual porción de la ruleta.



# Selección de los padres: Rank



En este, se elimina el concepto de un valor de aptitud al seleccionar un padre.

Sin embargo, cada individuo en la población se clasifica según su aptitud.

La selección de los padres depende del rango de cada individuo y no del estado físico. Los individuos con un ranking más alto son preferidos más que los que tienen ranking más bajos.

# Cruce




El operador de cruce es análogo a la reproducción y al cruce biológico. En este, se selecciona más de un padre y se producen uno o más descendientes utilizando el material genético de los padres.

## **Operaciones de cruce:**

- **Cruce de un punto**
- **Cruce multipunto**
- **Cruce uniforme**
- **Recombinación aritmética**

# Cruce de un punto


En este cruce de un punto, se selecciona un punto de cruce aleatorio y las colas de sus dos padres se intercambian para obtener nuevos descendientes.





# Cruce multipunto

El cruce multipunto es una generalización del cruce de un punto en el que se intercambian segmentos alternados para obtener nuevos descendientes.



# Cruce uniforme

En un cruce uniforme, no dividimos el cromosoma en segmentos, sino que tratamos cada gen por separado.

En esto, esencialmente lanzamos una moneda para cada cromosoma para decidir si se incluirá o no en la descendencia. También podemos desnivelar la moneda a uno de los padres, para tener más material genético en el niño de ese padre.



# Recombinación aritmetica

Esta se usa comúnmente para representaciones enteras y funciona tomando el promedio ponderado de los dos padres usando las siguientes fórmulas:

$$\text{Hijo1} = \alpha * \text{Padre1} + (1-\alpha) * \text{Padre2}$$

$$\text{Hijo2} = \alpha * \text{Padre2} + (1-\alpha) * \text{Padre1}$$

Obviamente, si  $\alpha = 0.5$ , ambos niños serán idénticos como se muestra en la siguiente imagen.



# Cruce de orden de Davis (OX1)

OX1 se utiliza para cruces basados en permutación con la intención de transmitir información sobre el orden relativo a los resortes.

Funciona así:

1. Cree dos puntos de cruce aleatorios en el elemento primario y copie el segmento entre ellos desde el primer elemento primario hasta el primer elemento secundario.


0	1	2	3	4	5	6	7	8	9
---	---	---	---	---	---	---	---	---	---

=>

			3	4	5	6			
--	--	--	---	---	---	---	--	--	--

# Cruce de orden de Davis (OX1)

- Ahora, comenzando desde el segundo punto de cruce en el segundo padre, copie los números restantes no utilizados del segundo padre al primer hijo, envolviendo la lista.



- Repita para el segundo niño con el papel de padre invertido.

# Mutación



En términos simples, la mutación se puede definir como un pequeño ajuste aleatorio en el cromosoma, para obtener una nueva solución.

Se usa para mantener e introducir diversidad en la población genética y generalmente se aplica con una baja probabilidad -  $p_m$ .


La mutación es la parte de la GA que está relacionada con la "exploración" del espacio de búsqueda. Se ha observado que la mutación es esencial para la convergencia de la GA, mientras que el cruce no lo es.

# Mutación

## Operadores de mutación:

### 1. Bit Flip

En esta mutación invertida, seleccionamos uno o más bits aleatorios y los volteamos. Esto se usa para GA codificados binarios.




### 2. Random resetting

Es una extensión del Bit flip para la representación entera. En esta, se asigna un valor aleatorio del conjunto de valores permisibles a un gen elegido al azar.

# Mutación


## 3. Swap mutation

Se seleccionan dos posiciones en el cromosoma al azar e intercambiamos los valores. Esto es común en las codificaciones basadas en permutación.



## 4. Scramble mutation

En este, de todo el cromosoma, se elige un subconjunto de genes y sus valores se mezclan o barajan aleatoriamente. Popular para permutaciones.






# Mutación

## 5. Inversión mutation

Se selecciona un subconjunto de genes como en la mutación codificada, pero en lugar de mezclar el subconjunto, simplemente invertimos toda la cadena en el subconjunto.



# Políticas de supervivencia



La Política de selección de supervivientes determina qué individuos se eliminarán y cuáles se mantendrán en la próxima generación.

Es crucial ya que debe garantizar que los individuos más aptos no sean expulsados de la población, mientras que al mismo tiempo se debe mantener la diversidad en la población.

Algunos GA emplean **elitismo**. En términos simples, significa que el miembro más apto actual de la población siempre se propaga a la próxima generación. Por lo tanto, bajo ninguna circunstancia se puede reemplazar al miembro más apto de la población actual.

# Políticas de supervivencia



La política más fácil es eliminar aleatoriamente a los miembros de la población, pero dicho enfoque frecuentemente tiene problemas de convergencia, por lo tanto, las siguientes estrategias son ampliamente utilizadas.

- Basado en edad
- Basado en la aptitud (fitness)

# Supervivencia basado en edad

En la selección basada en la edad, no tenemos una noción de aptitud. Se basa en la premisa de que cada persona está permitida en la población para una generación finita donde se le permite reproducirse; después de eso, es eliminada de la población sin importar qué tan buena sea su aptitud.



# Supervivencia basado en la aptitud

Los hijos tienden a reemplazar a los individuos menos aptos de la población. La selección de las personas menos aptas se puede hacer utilizando una variación de cualquiera de las políticas de selección descritas anteriormente: selección de torneos, selección proporcional de aptitud física, etc.

